SALES PREDICTION MACHINE LEARNING

VISÃO DO PROJETO

É um projeto de Ciência de Dados desenvolvido para analisar a relação entre investimentos em publicidade e vendas, além de construir um modelo capaz de estimar vendas a partir de diferentes combinações de orçamento publicitário.

O projeto usa dados de investimentos em três canais **TV, Rádio e Jornal** para treinar e comparar modelos de regressão. Após avaliar resultados, o modelo Random Forest foi selecionado para gerar previsões em novos cenários de investimento.

Objetivo principal — utilizar dados históricos e Machine Learning para compreender quais variáveis estão mais associadas às vendas e estimar resultados para novas combinações de investimento publicitário.

Repositório — https://github.com/FelipeGhensevPeres/Sales-Prediction-ML

PROBLEMA DE NEGÓCIO

Uma empresa investe em diferentes canais de publicidade e deseja compreender como esses investimentos se relacionam com suas vendas.

Sem uma análise baseada em dados, fica mais difícil identificar quais canais apresentam maior associação com os resultados e estimar o desempenho de novos cenários de investimento.

Busquei responder às perguntas —

- Qual canal de publicidade apresenta maior relação com as vendas?
- É possível prever as vendas a partir dos investimentos em TV, Rádio e Jornal?
- Qual modelo de Machine Learning tem melhor desempenho nesse problema?
- Como usar as previsões para apoiar a análise de novos cenários de investimento?

ABORDAGEM

Analisar os dados históricos, identificar relações entre as variáveis, treinar diferentes modelos de regressão, comparar suas métricas de desempenho e usar o modelo selecionado para estimar as vendas em novos cenários.

O projeto oferece suporte analítico à tomada de decisão. As previsões não garantem resultados comerciais reais, e a análise observacional não comprova relações de causa e efeito entre publicidade e vendas.

CONJUNTO DE DADOS

Conjunto de dados `advertising.csv`, que contém 200 registros e quatro colunas.

Variável	Descrição	Papel no modelo
`TV`	Investimento em publicidade na TV	Variável preditora
`Radio`	Investimento em publicidade no rádio	Variável preditora
`Jornal`	Investimento em publicidade em jornais	Variável preditora
`Vendas`	Resultado de vendas associado aos investimentos	Variável alvo

Os valores de investimento são apresentados na escala usada pela base original. A variável `Vendas` deve ser interpretada em milhões, conforme indicado no notebook.

VARIÁVEIS PREDITORAS E ALVO

Separadas em dois grupos —

- **X —** investimentos em TV, Rádio e Jornal, para realizar as previsões.
- **y —** Vendas, variável que o modelo procura estimar.

Essa separação é fundamental em um problema de aprendizado supervisionado, pois o modelo aprende a relacionar as características de entrada ao resultado observado.

EXPLORATORY DATA ANALYSYS (EDA)

Para o EDA usei — **Pandas**, **Seaborn** e **Matplotlib**.

Os dados foram carregados em um DataFrame e inspecionados para entender sua estrutura, variáveis e os valores presentes na base.

MATRIZ DE CORRELAÇÃO

Foi calculada a matriz de correlação entre as variáveis numéricas e criado um heatmap para visualizar as relações entre os investimentos e as vendas.

A correlação ajuda a identificar associações lineares entre variáveis, lembrando sempre que não necessariamente demonstra causalidade.

PRINCIPAIS OBSERVAÇÕES

- **TV —** maior correlação com as vendas entre os canais analisados.
- **Rádio —** correlação intermediária com as vendas.
- **Jornal —** correlação mais baixa com as vendas.

As observações ajudaram a entender melhor os dados antes da etapa de modelagem e ajudaram a análise a seguir da importância das variáveis no Random Forest.

PREPARAÇÃO DOS DADOS

SEPARAÇÃO ENTRE X E Y

A variável `Vendas` foi definida como alvo (`y`), enquanto as colunas `TV`, `Radio` e `Jornal` foram usadas como preditoras (`X`).

DIVISÃO ENTRE TREINO E TESTE

Função `train_test_split`, do Scikit-Learn, para dividir os dados —

- **70% para treinamento:** 140 registros.
- **30% para teste:** 60 registros.
- `random_state=42` mantém a divisão reproduzível.

O conjunto de treinamento é usada para ajustar os modelos. O conjunto de teste é para avaliar como eles preveem resultados em registros que não foram usados no ajuste.

MODELAGEM

Foram treinados dois modelos de regressão para a variável contínua `Vendas`.

LINEAR REGRESSION

Regressão Linear como modelo de referência ***baseline***.

O algoritmo procura representar a relação entre as variáveis preditoras e a variável alvo por meio de uma combinação linear.

- É relativamente simples de interpretar.
- Permite estabelecer uma referência inicial de desempenho.
- Ajuda a comparar o ganho obtido com um algoritmo mais flexível.

RANDOM FOREST REGRESSOR

O Random Forest Regressor combina várias árvores de decisão para produzir uma previsão de regressão.

Em vez de depender de uma única árvore, o algoritmo combina resultados de diversas árvores, do capturando padrões não lineares e relações complexas entre as variáveis.

Configuração que usei —

Parâmetro	Valor	Finalidade
`n_estimators`	`200`	200 árvores no conjunto
`random_state`	`42`	para reprodutibilidade
`n_jobs`	`-1`	para usar todos os processadores disponíveis para paralelizar o treinamento e ter mais velocidade

A comparação entre modelos ajuda a ver se um modelo mais flexível **(Random Forest)** tem ganhos em relação a uma abordagem mais simples **(Linear**

Regression).

Com isso, o Random Forest teve resultados melhores nas duas métricas usadas, sendo selecionado para as próximas previsões.

AVALIAÇÃO DOS MODELOS

Os modelos foram avaliados usando o conjunto de teste e duas métricas: MAE e R^2.

MAE — MEAN ABSOLUTE ERROR

Representa a média dos valores absolutos das diferenças entre as previsões e os valores reais.

Indicando o tamanho médio do erro de previsão, sem considerar se o modelo superestimou ou subestimou o resultado.

Quanto menor o MAE, menor o erro absoluto médio.

R^2 — COEFICIENTE DE DETERMINAÇÃO

O R^2 compara o desempenho do modelo com uma referência baseada na média dos valores observados, avaliando quanto da variabilidade da variável-alvo é explicada pelo modelo no conjunto avaliado.

Em situações de regressão, valores mais próximos de 1 indicam melhor ajuste em relação a essa referência. O R^2 também pode ser negativo.

Quanto maior o R^2, melhor o desempenho do modelo nessa métrica.

RESULTADOS OBTIDOS

Os valores abaixo são os resultados registrados no notebook, com duas casas decimais.

Modelo	MAE	R^2
Linear Regression	1,16	0,91
Random Forest	1,01	0,94

O Random Forest teve—

- MAE menor — indicando menor erro absoluto médio no conjunto de teste.
- R^2 maior — melhor desempenho relativo na explicação da variabilidade das vendas nesse conjunto.

Como a variável `Vendas` está expressa em milhões, o MAE deve ser interpretado na mesma escala. Um MAE de 1,01 corresponde a um erro absoluto médio de aproximadamente 1,01 unidade da variável-alvo — ou seja, aproximadamente 1,01 milhão de vendas, conforme a unidade definida para a base.

Os resultados favorecem o Random Forest, mas não garantem que ele terá desempenho superior em todos os conjuntos de dados ou em dados futuros.

VISUALIZAÇÃO DAS PREVISÕES

Foram criadas visualizações para comparar os valores reais com os valores previstos pelos dois modelos.

PREVISÕES VS. VALORES REAIS

O gráfico de dispersão compara as vendas reais com as estimativas produzidas pelo modelo. Uma linha diagonal representa a situação ideal em que a previsão é igual ao valor real.

- **Pontos próximos da diagonal —** previsões próximas dos valores observados.
- **Pontos afastados da diagonal —** diferenças maiores entre previsões e valores reais.
- **Dispersão menor em torno da diagonal —** indica maior proximidade dos valores previstos e reais.

COMPARAÇÃO ENTRE MODELOS

Uma função adicional ajuda a visualizar as previsões da Regressão Linear e do Random Forest no mesmo gráfico.

Essa comparação ajuda as métricas numéricas e facilita a identificação visual de diferenças dos modelos.

ANÁLISE DA IMPORTÂNCIA DAS VARIÁVEIS

Após o treinamento, usei a `feature_importances_` do Random Forest para vera importância das variáveis preditoras.

Os valores foram organizados em um DataFrame e apresentei eles em um gráfico de barras.

RESULTADOS REGISTRADOS

Variável	Importância aproximada
TV	85%
Rádio	13%
Jornal	2%

TV — 85%

Foi a variável com maior importância nas previsões do Random Forest.

Rádio — 13%

Teve contribuição menor que TV, mas superior à de Jornal.

Jornal — 2%

Teve a menor importância entre as três variáveis consideradas pelo modelo.

A importância de uma variável no Random Forest representa sua contribuição para as divisões das árvores, segundo a medida usada pelo algoritmo. Ela não é uma medida de causalidade e não significa necessariamente que 85% das vendas sejam causadas pela publicidade na TV.

SELEÇÃO DO MODELO FINAL

Random Forest Regressor foi selecionado como modelo final.

A escolha foi feita se baseando no desempenho no conjunto de teste —

- Menor **MAE: 1,01**
- Maior **R^2: 0,94**

- Capacidade de representar relações não lineares.
- Facilidade de ter uma medida de importância das variáveis.

O modelo final foi então usado para prever vendas em novas combinações de investimentos em TV, Rádio e Jornal.

GERAÇÃO DE NOVOS CENÁRIOS DE INVESTIMENTO

Além da previsão nos dados de teste, inclui uma etapa de gerar dados sintéticos e simular novas combinações de investimento publicitário.

GERAÇÃO DOS DADOS

O script `scripts/gerar_dados_novos.py` usa o Pandas e NumPy, gerando 100 combinações de investimento.

Os valores são sorteados de distribuições uniformes dentro dos intervalos definidos no código:

Variável	Intervalo utilizado
TV	De 0 a 300
Rádio	De 0 a 50
Jornal	De 0 a 120

Os valores são arredondados para uma casa decimal e exportados para `data/novos_gerados.csv`.

O uso de `np.random.seed(42)` ajuda a reproduzir os mesmos dados gerados em execuções equivalentes.

esses registros são cenários criados apenas para simulação. Não representam investimentos reais de uma empresa.

PREVISÃO DOS NOVOS CENÁRIOS

No notebook principal, o arquivo `novos_gerados.csv` é carregado e usado como entrada do Random Forest já treinado.

A previsão é adicionada a uma nova coluna — `Previsao_Vendas`

Cada linha passa a conter os investimentos simulados e a estimativa de vendas correspondente.

Os resultados são exportados para `data/previsoes.csv`, permitindo consultar as previsões fora do notebook.

A simulação mostra como um modelo treinado pode ser usado para produzir previsões a partir de novas entradas de dados, sem precisar treinar novamente o algoritmo para cada combinação.

Porem as previsões são estimativas baseadas nos padrões aprendidos na base histórica. E não garantem que um cenário com determinado investimento vai produzir exatamente o valor previsto.

ORGANIZAÇÃO DO CÓDIGO

Organizei o projeto em pastas para separar os dados, o notebook de análise, as funções para reutilização e o script de geração de dados.

```
Sales-Prediction-ML/
│
├── data/
│   ├── advertising.csv
│   ├── novos.csv
│   └── novos_gerados.csv
│
├── functions/
│   ├── __init__.py
│   ├── avaliacoes.py
│   └── visualizacoes.py
│
├── notebooks/
│   └── main.ipynb
│
├── scripts/
│   └── gerar_dados_novos.py
│
├── .gitignore
├── requirements.txt
└── README.md
```

`notebooks/main.ipynb`

É o notebook principal do projeto.

Possui o carregamento dos dados, EDA, a separação entre treino e teste, o treinamento dos modelos, a avaliação, os gráficos, a análise de importância das variáveis e a previsão de novos cenários.

`functions/avaliacoes.py`

Contém a função `avaliar_modelo()`, que calcula e organiza as métricas de avaliação.

A função recebe o nome do modelo, os valores reais e as previsões; calcula **MAE e R^2.** Arredonda os resultados para duas casas decimais e retorna um DataFrame com os resultados.

Essa função ajuda a evitar repetir o mesmo código de avaliação para cada modelo e facilita futuras comparações.

`functions/visualizacoes.py`

Contém funções para gerar gráficos.

- `plot_previsoes() --` compara os valores reais e previstos em um gráfico de dispersão, com uma diagonal de referência.
- `plot_comparacao() --` apresenta as previsões de dois modelos no mesmo gráfico.

`scripts/gerar_dados_novos.py`

Gera os 100 cenários novos de investimento e salva os resultados em CSV.

Separando essa parte em um script próprio permite gerar novos dados sem misturar a lógica de simulação com todo o código de modelagem.

`requirements.txt`

São as principais bibliotecas necessárias que usei no ambiente do projeto —

- `pandas`
- `numpy`

- `matplotlib`
- `seaborn`
- `scikit-learn`
- `jupyter`

ARQUIVOS CSV

- `advertising.csv --` base usada para treinar e avaliar os modelos.
- `novos.csv --` arquivo de dados adicionais.
- `novos_gerados.csv --` combinações novas usadas para gerar previsões novas.

No fluxo atual, a etapa de previsão utiliza `novos_gerados.csv`. O arquivo `previsoes.csv` é gerado durante a execução do notebook.

TECNOLOGIAS QUE USEI

Tecnologia	No projeto
Python	Linguagem principal
Pandas	Leitura, manipulação e organização dos dados
NumPy	Geração de valores e ajuda numérica
Scikit-Learn	Divisão dos dados, treinamento dos modelos e avaliação
Matplotlib	Gráficos
Seaborn	Heatmap de correlação e visualização da importância de variáveis
Jupyter Notebook	Desenvolvimento e documentação da análise
Git	Controle de versão
GitHub	Armazenamento e apresentação do projeto
Notion	Documentação

PRINCIPAIS RESULTADOS

CONCLUSÃO GERAL

Fluxo de trabalho de Machine Learning aplicado a um problema de regressão — parte da análise dos dados, passa pela preparação e modelagem, compara métricas e usa o modelo selecionado para produzir previsões.

Os resultados registrados indicam que o Random Forest teve melhor desempenho que a Regressão Linear no conjunto de teste. A análise de importância também destacou TV como a variável mais importante para as previsões desse modelo.

Esses resultados podem ajudar a hipóteses novas e criar cenários de investimento, mas não devem ser interpretados como prova de causalidade nem como garantia de retorno comercial. Foi totalmente para estudo e treino do meu conhecimento!!

POSSÍVEIS MELHORIAS

VALIDAÇÃO E DESEMPENHO

- Usar Cross Validation para avaliar a estabilidade do desempenho.
- Testar outros modelos de regressão, como Decision Trees, Gradient Boosting.
- Otimização de hiperparâmetros com GridSearchCV ou RandomizedSearchCV.
- Comparar as métricas em diferentes divisões dos dados.

ANÁLISE E INTERPRETABILIDADE

- Investigar resíduos para identificar padrões nos erros.
- Comparar a importância das variáveis com técnicas complementares, como Permutation importance.
- Investigar relações não lineares e possíveis interações entre os canais.

SIMULAÇÃO E APLICAÇÃO DE NEGÓCIO

OBS — Essa parte de melhoria não é 100% aplicável pois a base veio de um curso então pode ser apenas fictícia.

- Permitir que o usuário informe manualmente os investimentos e obtenha uma previsão.
- Criar gráficos comparando cenários de investimento.
- Avaliar cenários dentro dos intervalos e condições representados pela base original.
- Obter dados mais recentes e representativos de campanhas reais.
- Investigar métodos adequados para estimar o efeito causal de alterações no orçamento publicitário antes de recomendar mudanças de investimento.

ORGANIZAÇÃO E REPRODUTIBILIDADE

- Revisar os caminhos dos arquivos para facilitar a execução a partir da raiz do repositório.
- Criar testes para as funções de avaliação e visualização.

Essas são possibilidades de evolução, não funcionalidades já implementadas na versão documentada.

LINKS DO PROJETO

- **Repositório no GitHub —** https://github.com/FelipeGhensevPeres/Sales-Prediction-ML
- **Notebook main —** https://github.com/FelipeGhensevPeres/Sales-Prediction-ML/blob/main/notebooks/main.ipynb
- **Módulo de avaliação —** https://github.com/FelipeGhensevPeres/Sales-Prediction-ML/blob/main/functions/avaliacoes.py
- **Módulo de visualização —** https://github.com/FelipeGhensevPeres/Sales-Prediction-ML/blob/main/functions/visualizacoes.py
- **Script da geração de dados —** https://github.com/FelipeGhensevPeres/Sales-Prediction-ML/blob/main/scripts/gerar_dados_novos.py

---

RESUMO FINAL

O **Sales Prediction Machine Learning** usa dados históricos de investimentos em TV, Rádio e Jornal para prever vendas. Após análise exploratória, separar os dados em treino e teste e comparar 2 modelos — Regressão Linear com Random Forest, o Random Forest foi selecionado por apresentar melhor desempenho nas métricas que foram avaliadas. O projeto também analisa a importância relativa das variáveis e usa dados sintéticos para gerar novas previsões em 100 cenários de investimento. Os resultados demonstram a aplicação prática de um fluxo de Machine Learning, mantendo a distinção entre previsões, associações estatísticas e relações causais.